

# Тестовое задание

---

## Исследование поисковых запросов маркетплейса

### Описание задачи

Вы работаете в команде «Понимание запросов» крупного e-commerce маркетплейса. Ваша задача — исследовать поисковые запросы пользователей, найти в них закономерности и попытаться извлечь **атрибуты** товаров

**Атрибуты** - здесь и далее, характеристики и параметры искомым пользователем товаров (категории товаров, бренды, размеры, цвета и др.)

Это задание проверяет ваши навыки аналитического мышления, работы с данными и понимание специфики e-commerce.

### Исходные данные

Вам предоставлен CSV-файл `test_queries_sample.csv`, содержащий 20 000 поисковых запросов пользователей маркетплейса.

Формат данных:

| Колонка            | Описание                 |
|--------------------|--------------------------|
| <code>query</code> | Текст поискового запроса |

### Часть 1. Знакомство с данными

Загрузите данные и проведите разведочный анализ (EDA). Попробуйте рассмотреть различные статистики, их распределение на запросах. Запросы можно векторизовать и кластеризовать, по-разному объединять и т.п. В общем, попытайтесь извлечь максимум информации из запросов пользователей.

### Часть 2. Извлечение атрибутов (Rule-based)

Напишите на Python функции для извлечения **атрибутов** из запросов БЕЗ использования вызовов локальных или внешних LLM. Вы можете использовать правила, логику, RegEx, ML модели - любые инструменты кроме LLM. Однако, LLM можно использовать для разметки данных/генерации синтетики/ресерча и т.п. Вы

можете извлекать любые атрибуты из запросов, однако, преимуществом будет извлечение наиболее встречаемых атрибутов с хорошей точностью и полнотой. При этом, чем больше различных атрибутов будет извлекаться из запросов с хорошим качеством, тем лучше.

### Часть 3. Анализ извлеченных атрибутов

Используя результаты извлечения атрибутов, посмотрите на их распределение, типичные ошибки, сложные и двусмысленные запросы, в общем, постарайтесь дать описание и оценку вашим решениям, а также предложите дальнейшие шаги для их улучшения.

### Технические требования

- Язык: Python 3.9+
- Код должен быть читаемым, с комментариями и docstrings
- Результаты должны быть воспроизводимы (фиксируйте random seed, если используете случайность), обязательно приложите описание зависимостей (requirements.txt)

Формат сдачи:

- PDF, сконвертированный из Jupyter Notebook (.ipynb)
- Сам Jupyter Notebook (.ipynb)
- [README.md](#) с кратким описанием, как запускать ноутбук (если есть необходимость в доп. описании)
- requirements.txt

**Удачи! Мы с нетерпением ждем ваше решение.**